


1. Abstract


리튬 이온 배터리는 반복되는 충·방전 사이클로 인해 내부 분리막에 불순물이 침전되고, 이로 인해 내부 저항이 증가하면서 용량이 영구적으로 감소하게 됩니다. 특히 높은 충전 전류, 고온, 높은 충전 상태(SoC)에서 보관될 경우 이러한 화학 반응이 가속화되어 배터리 열화가 더 심해집니다. 그러나 현재 대부분의 산업 및 소비자용 전자기기에서는 이러한 변수들을 종합적으로 고려하는 정밀한 배터리 관리 시스템이 부족하여, 과충전, 과방전, 발열 및 수명 저하 문제가 빈번하게 발생하고 있습니다.

본 프로젝트는 이러한 한계를 극복하고자 AI 기반 강화학습과 실시간 센서 제어 기술을 결합한 스마트 배터리 관리 시스템을 구현하는 것을 목표로 합니다. 기존 일반 충전 방식은 사전에 설정된 임계값만으로 충전을 제어하지만, AI 기반 충전 제어는 배터리의 현재 상태와 미래 영향을 종합적으로 고려하여, 매 순간 충전과 비충전 중 어떤 선택이 장기적으로 배터리 수명을 늘리고 효율을 높일지 학습하여 결정합니다. 이를 통해 배터리 수명을 연장하고 에너지 효율을 높이며, 보다 안전하고 안정적인 충전 환경을 제공하는 것을 목표로 합니다.

System Overview



Components



2. Data Sensing

2-1. 전압, 전류 측정

INA219와 MCP3008로 배터리의 정확한 전압, 전류 측정

리튬 이온 배터리 내부의 전압과 전류를 측정하기 위해 건전지의 양극단을 INA219와 연결하여 I2C 통신으로 전류와 전압값을 구한다. 전류는 그대로 디지털 신호로 출력되지만, 전압은 아날로그 값으로 출력해내려는 문제가 있으므로 MCP3008 ADC 컨버터를 전압 출력핀과 연결하여 디지털 신호로 변환하여 출력하도록 구성하였다. 이때 MCP3008에 전압을 입력할 때 최대 입력 전압이 넘어서는 안 되기 때문에 10k옴과 10k옴 사이에 연결하였다. 이때 분배비는 1:1이므로 ADC에서 측정된 전압을 2배로 하여 실제 전압을 추산한다. 충전 중에 과전압(4.26V 이상) 및 과전류(3.5A 이상)가 감지되면 자동으로 충전을 멈추도록 설계하였다.

온도 측정

DS18B20 센서로 현재 배터리가 위치한 주변 온도를 측정

아날로그 신호로 받아낸 원시 온도를 1000으로 나누어서 섭씨로 변환한 후, 최종 온도를 구해낸다. 충전 중에 온도가 41도 이상 감지되면 자동으로 충전을 멈추도록 설계하였다.

2-2. SoC 측정

전압 기반으로 배터리의 잔량을 추정
구간별 Soc 계산

$SOC(V) = \begin{cases} 100, & V \geq 4.2 \\ 80 + (V - 3.8) \times 20 / 0.4, & 3.8 \leq V < 4.2 \\ 50 + (V - 3.5) \times 30 / 0.3, & 3.5 \leq V < 3.8 \\ 20 + (V - 3.3) \times 30 / 0.2, & 3.3 \leq V < 3.5 \\ \max(0, (V - 3.0) \times 20 / 0.3), & V < 3.3 \end{cases}$	4.2V 이상 → 100% 3.8V ~ 4.2V → 80~100% 3.5V ~ 3.8V → 50~80% 3.3V ~ 3.5V → 20~50% 3.0V ~ 3.3V → 0~20%
---	--


2-3. SoH 측정

전류, 전압 기반으로 배터리의 건강 상태를 추정

SoH를 측정하기 위해서는 Re(전해액 저항), Rct(전하 이동 저항)를 측정해야 정확한 배터리 건강 상태를 알아낼 수 있다. 하지만 리튬 이온 배터리의 내부저항은 직접 측정하는데 드는 비용이 크므로 소프트웨어적으로 해결하는 방법으로 대체하였다.

본 프로젝트에서 구현한 Soh 측정 방법은 다음과 같다.

1. INA219 센서로부터 실시간으로 받아내는 전압, 전류를 측정하여 아래 그림에 보인 Re와 Rct 값을 구한 후, SoH를 계산한다.



2. NASA의 1셀 기준 Li-ion Battery Aging Dataset(Battery_Data.csv)을 불러와서 위에서 계산된 현재 측정된 SoH와 비교 후, 용량 차를 보정하여 근사화된 SoH를 구한다.

3. 이때 구한 SoH는 정확한 Re, Rct 저항값이 아니고 실시간으로 구해진 전압과 전류에 의한 값이므로 SoH 값의 변동이 크기 때문에 smoothing 기법을 이용하여 SoH의 오차값을 최소화하여 실제에 근접한 SoH를 구해낸다.

배터리 사양 비교	(프로젝트) 리튬이온 배터리	NASA Dataset
형태	18650	18650
정격 전압	3.6V	3.6V
정격 용량	3450mAh	2000mAh
테스트 온도	24~43 °C	24~43 °C
충전 전압	4.2V	4.2V
방전	고율 5A (1.45C) 일반 680mA (0.2C) (일반은 비교 대상x)	고율 2A (1.8C)

2-4. 충전 USB의 입력 인식

충전 USB를 라즈베리파이의 USB 단자에 꽂으면 라즈베리파이로부터 5V 전압으로 충전하도록 설계되어 있다.

이때 UART 통신으로 단자의 입력을 인식하고 충전을 시작한다. USB 단자를 빼면 충전기를 뺐 것으로 간주하고 배터리 충전을 멈춘다. 충전 입력 확인 방식은 유선 통신 방식이므로 RX, TX 선이 연결되어 있다.

3. AI Technology

3-1. Q-Learning

1. Bellman EQ



$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \cdot \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$

Q-learning은 보상과 다음 상태의 최대 Q값을 기반으로 현재 Q값을 갱신해가며 최적의 정책을 학습하는 강화학습 방법입니다.

2. DQN 손실 함수 (신경망 기반 Q-function 근사)

$$\mathcal{L} = [r + \gamma \cdot \max_{a'} Q_{\text{target}}(s', a') - Q(s, a)]^2$$

DQN (Deep Q-Network) 은 Q-learning의 핵심 개념을 그대로 가져오면서, 테이블 대신 신경망을 이용해 Q값을 근사합니다. 타깃 네트워크와 경험 리플레이 버퍼를 활용해 학습의 안정성과 수렴성을 높입니다.



3-2. 심층강화학습의 최적화 구성

1. 최적화 목적

→ 장기적으로 누적 보상이 최대가 되는 충전/비충전 행동 시퀀스를 찾는다. 수식으로 표현하면 다음과 같다.

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

r: reward.py에 정의된 리워드 함수로 정의되어 있다.

리워드는 다음을 정량화하고 있다.

- 충전 시점의 적절성(SoC 기준)
- 상태 전환의 안정성(prev_action 비교)
- 온도 기준의 위험 회피
- 장기적 사이클 안정성

위 4개의 정량화를 통해 충전 효율 + 안정성 + 예측 제어를 수치로 표현 가능하다.

2. 제어 변수

시스템이 선택할 수 있는 행동

$$a \in \{0, 1\} \quad (0 = \text{충전 OFF}, 1 = \text{충전 ON})$$

DQN은 현재 상태 아래 식에 따라 최적의 행동 a를 선택함으로써 제어를 수행한다.

$$s_t = [\text{SoC}_t, \text{Temp}_t]: \text{상태}$$

3. 제약 조건

다음 조건들을 리워드에 반영함

Temp ≥ 41°C → 충전 OFF (또는 큰 페널티)

SoC > 80% → 충전 자체 유도 (보상 감소)

전류/전압: 일정 범위를 벗어나면 조건문 기반으로 강제 off

→ 일부는 리워드 함수에, 일부는 시스템 안전장치(if문)로 구현되어 있고, 경험 내에서 soft constraint + hard constraint를 함께 고려하였다.

4. 작동 흐름

01 실시간 데이터 수집

센서값을 바탕으로 전류, 전압, 온도 값 추출

```
voltage = bus.voltage + shunt_voltage  
current = ina219.current  
temp_c = float(lines[1].split('t=')[1]) / 1000.0
```

02 상태 계산 및 추정

Re, Rct 저항 기반 SoH 계산 및 전압에 따른 구간별 SoC 계산

SoH	SoC
Re_now = V / I	4.2V 이상 → 100%
Rct_now = (V - 3.0) / I	3.8V ~ 4.2V → 80~100%
SOH = 1/2 * (Re_ / Re_now + Rct_ / Rct_now) * 100	3.5V ~ 3.8V → 50~80%
	3.3V ~ 3.5V → 20~50%
	3.0V ~ 3.3V → 0~20%

03 AI 기반 충전 제어

1. 실시간 센서 데이터, 리워드, 충전 상태를 memory.py에 저장.

2. 이후 들어온 데이터와 비교 분석해 장기 누적 리워드가 최대가 되는 충전 행동을 학습하여 배터리 수명 최적화를 위한 지능형 충전 제어

3. 이상 감지에 따른 충전 자동 중지

온도 ≥ 41 C
전압 ≥ 4.26 V → 충전 중단 및 경고 알림
전류 ≥ 3.5 A

04 사용자 인터페이스


• UI 화면에 배터리 상태 및 충전 진행 상황 실시간 표시

• 수동 충전 제어 가능 (수동모드로 전환)


• 충전 조건 시뮬레이션 가능

5. Result

5-1. Final product




5-2. User Interface




5-3. 학습 성능 평가



a. 학습 손실 추이



b. 탐험 비율



c. 리워드 추이

5-4. 적용 분야

1. 드론

완전충전-완전방전 방식
수명이 짧아 배터리 교체 주기 짧음
평균 비행 시간이 짧음

2. 전통 킷보드 / 전기 자전거

단순한 배터리 보호회로만 갖추고 있음
완전충전-완전방전 방식
기준에 따라 배터리 성능 저하



배터리 수명 연장 → 사이클 수 증가

SOC 추정 정확도 향상 → 비행시간, 이동거리 예측 정확도

배터리 상태 시각적 제공 → 사용자 신뢰도 향상